

KOCAELİ ÜNİVERSİTESİ BİLGİSAYAR MÜHENDİSLİĞİ

YAZILIM LABORATUVARI – II PROJE – I

Web Scraping Tabanlı Kentsel Haber İzleme ve Harita Üzerinde Görselleştirme Sistemi

Saffet Hakan KOÇAK
Bilgisayar Mühendisliği
Kocaeli Üniversitesi
230202058

Yusuf BÜLBÜL
Bilgisayar Mühendisliği
Kocaeli Üniversitesi
230202050

ÖZET

Bu projede, Kocaeli iline ait yerel haber kaynaklarından otomatik veri toplayan, bu verileri işleyip sınıflandıran ve Google Maps üzerinde görselleştiren web scraping tabanlı bir kentsel haber izleme sistemi tasarlanmış ve gerçekleştirilmiştir. Projenin temel amacı, farklı yerel haber sitelerinde dağınık halde bulunan trafik kazası, yangın, elektrik kesintisi, hırsızlık ve kültürel etkinlikler gibi şehir yaşamını doğrudan etkileyen olayları tek bir platformda birleştirerek kullanıcıya konum tabanlı ve filtrelenebilir bir izleme altyapısı sunmaktır.

Sistem mimarisi; veri toplama, veri temizleme, haber sınıflandırma, konum çıkarımı, koordinat dönüştürme, veritabanında saklama ve kullanıcı arayüzünde harita tabanlı gösterim olmak üzere çok aşamalı bir yapıdan oluşmaktadır. Veri toplama aşamasında Kocaeli'ye ait yerel haber sitelerinden web scraping teknikleri ile haber başlığı, içerik, tarih, kaynak ve bağlantı bilgileri elde edilmiştir. Elde edilen metinler üzerinde HTML etiket temizliği, boşluk ve özel karakter temizliği, metin normalizasyonu ve gereksiz içeriklerin ayıklanması gibi ön işleme adımları uygulanmıştır. Sistem içerisinde haber türü belirleme işlemi anahtar kelime tabanlı puanlama yaklaşımı ile otomatik olarak gerçekleştirilmiş; haber başlığı ve içerik birlikte değerlendirilerek her haber tek bir kategori altında sınıflandırılmıştır.

Konum tabanlı görselleştirme için haber metinlerinden ilçe, mahalle ve cadde/sokak düzeyinde yer bilgileri çıkarılmış, ardından bu metinsel konumlar Google Geocoding API kullanılarak enlem-boylam bilgilerine dönüştürülmüştür. Aynı konum için tekrar eden API çağrılarını azaltmak amacıyla in-memory önbellekleme mekanizması uygulanmıştır. Tekrarlanan veya farklı kaynaklarda benzer şekilde yayımlanan haberlerin tespiti için metin benzerliği analizi yapılmış; aynı olaya ait kayıtlar birleştirilerek kaynak bilgileri birlikte tutulmuştur. Tüm haber verileri MongoDB veritabanında saklanmış; Express tabanlı servis katmanı üzerinden istemciye sunulmuştur.

Geliştirilen kullanıcı arayüzünde haberler Google Maps üzerinde işaretleyiciler ile gösterilmiş, olay türlerine göre

farklı renk ve semboller kullanılmıştır. Kullanıcıların tarih aralığına, haber türüne ve ilçe bilgisine göre dinamik filtreleme yapabilmesi sağlanmıştır. Böylece proje sonucunda, Kocaeli için yerel olayların otomatik toplanmasını, analiz edilmesini ve harita üzerinde etkileşimli biçimde izlenmesini mümkün kılan bütünlük bir bilgi izleme sistemi ortaya konulmuştur.

I. GİRİŞ

Günümüzde trafik kazaları, yangın olayları, elektrik kesintileri, hırsızlık olayları ve kültürel etkinlikler gibi şehir yaşamını doğrudan etkileyen gelişmeler çoğunlukla yerel haber siteleri aracılığıyla duyurulmaktadır. Ancak bilgilerin farklı kaynaklarda dağınık şekilde bulunması, kullanıcıların güncel olayları hızlı ve bütüncül bir biçimde takip etmesini zorlaştırmaktadır. Özellikle belirli bir şehir veya ilçe özelinde konum tabanlı olay takibi yapmak isteyen kullanıcılar için, haberlerin sadece metin olarak sunulması yerine sınıflandırılmış ve harita üzerinde görselleştirilmiş bir altyapı sunmak önem kazanmaktadır.

Bu projede, Kocaeli iline ait yerel haber kaynaklarından otomatik olarak veri toplayan, bu verileri işleyerek anlamlı hale getiren ve harita tabanlı bir arayüz üzerinde kullanıcıya sunan bütünlük bir sistem geliştirilmiştir. Sistem; web scraping, metin ön işleme, haber sınıflandırma, konum çıkarımı, koordinat dönüştürme, veritabanı yönetimi ve web tabanlı görselleştirme bileşenlerinden oluşmaktadır. Böylece farklı haber sitelerinde yayınlanan olay içerikleri tek bir platform altında toplanarak kullanıcıya merkezi bir izleme ortamı sağlanmıştır.

Geliştirilen yapıda, haberler belirli bir zaman aralığına göre çekilmekte; başlık, içerik, tarih, kaynak ve bağlantı bilgileri sistem tarafından işlenmektedir. Ham metinler temizlenip normalleştirildikten sonra trafik kazası, yangın, elektrik kesintisi, hırsızlık ve kültürel etkinlikler kategorileri için anahtar kelime tabanlı puanlama yöntemi uygulanarak haberler otomatik olarak sınıflandırılmaktadır. Ardından haber metinlerinden ilçe ve mahalle/cadde/sokak düzeyinde konum ifadeleri çıkarılır; bu metinler Google Geocoding API ile enlem-boylama dönüştürülerek harita üzerinde görselleştirilir.

Projenin bir diğer önemli amacı, farklı haber kaynaklarında yer alan tekrar eden veya benzer içerikli haberleri tespit ederek veri bütünlüğünü korumaktır. Bu doğrultuda, haberler arasında benzerlik analizi yapılarak aynı olaya ait kayıtların tekilleştirilmesi hedeflenmiştir. Benzersiz olarak belirlenen haberler MongoDB’de saklanmış; Express tabanlı bir arayüz üzerinden istemciye aktarılmıştır. Kullanıcı arayüzünde ise haberler olay türüne göre farklı işaretleyicilerle gösterilmiş, ayrıca tarih aralığı ve ilçe bazında dinamik filtreleme desteklenmiştir.

Bu raporda, geliştirilen sistemin tasarım süreci, kullanılan yöntemler, yazılım mimarisi, veri işleme adımları, sınıflandırma ve konum çıkarımı yaklaşımları ile harita tabanlı görselleştirme yapısı ayrıntılı olarak açıklanmaktadır.

II. YÖNTEM

Bu bölümde, sistemin yazılım katmanında yer alan veri toplama, ön işleme, sınıflandırma, konum çıkarımı, benzerlik analizi ve görselleştirme adımları detaylandırılmaktadır.

A. Veri Toplama (Scraping)

Sistem, haber içeriklerini yerel haber sitelerinden otomatik biçimde elde etmek üzere web scraping yaklaşımıyla çalışmaktadır. Projede bazı kaynaklar Cloudflare benzeri koruma katmanlarına sahip olduğundan, bu siteler için tarayıcı tabanlı çekim yöntemi tercih edilmiştir. Bu amaçla ‘puppeteer-real-browser’ kullanılarak tarayıcı bağlantısı kurulmuş; Cloudflare turnstile/challenge başlıkları tespit edilerek sayfa yükleme süreci bekletilmiştir. Bu tarayıcıdan elde edilen cookie ve user-agent bilgileri kullanılarak ilgili haber sayfalarının HTTP istekleri ile içerikleri çekilmiştir.


Cloudflare korumalı kaynaklar tek tarayıcı örneği üzerinde ardışık şekilde taranırken, ‘axios’ ve ‘cheerio’ ile içerik çekilebilen kaynaklar paralel şekilde işlenmektedir. Kaynaklardan toplanan her haber için; başlık (‘title’), içerik (‘content’), yayın tarihi (‘date’), kaynak adı (‘source’) ve bağlantı (‘link’) bilgileri elde edilmektedir. Ayrıca sayısal/format olarak doğrulanamayan tarih değerleri atlanmaktadır.

Elde edilen scraping çıktıları geliştirme aşamasında izlenebilir olması için JSON snapshot dosyalarına yazdırılabilmektedir. Her kaynak güncelleme başlamadan önce snapshot durumu sıfırlanarak tutarlılık sağlanmaktadır.

B. Veri Temizleme ve Normalizasyon

Haber başlıkları ve içerikleri, tutarsız Unicode işaretleri, görünmez karakterler, HTML gömülü ifadeler ve reklam/-sosyal paylaşım bölümleri gibi gürültüler içerebilmektedir. Bu nedenle sistemde ‘cleanText’ fonksiyonu ile ön işleme uygulanmıştır. Temizleme adımları şu şekildedir:

- Unicode normalizasyonu ve görünmez karakter temizliği,
- HTML etiketlerinin kaldırılması,




Şekil 1: Haber Çekimi

- HTML entity dönüşümleri (ör. ‘amp;’ vb.),
- satır sonu/boşluk birleştirme,
- metni analiz için uygun olacak şekilde izinli karakter seti kısıtlaması.

Bu sayede sınıflandırma ve benzerlik analizine giden metinler standardize edilmiştir.

C. Haber Sınıflandırma (Olay Türü)

Haber sınıflandırma işlemi, anahtar kelime tabanlı bir puanlama yaklaşımıyla gerçekleştirilmiştir. classifier.js dosyasında, her olay kategorisi için anahtar kelime kümeleri (KEYWORDS) ve olumsuz anahtar kelime kümeleri (NEGATIVE_KEYWORDS) tanımlanmıştır. Sınıflandırma sürecinde haber başlığı ve içerik ayrı ayrı değerlendirilmiş; başlık kısmı için TITLE_MULTIPLIER = 3, içerik kısmı için ise CONTENT_MULTIPLIER = 1 ağırlıkları kullanılmıştır.



Şekil 2: Haber Sınıflandırma

Algoritma, her kategori için anahtar kelimelerin metin içinde bulunmasına göre bir ‘matchScore’ üretir; ayrıca olumsuz anahtar kelimeler bulunduğunda ilgili kategori puanı ceza ile düşürülür. En yüksek puanı alan kategori, ‘selectedCategory’ olarak döndürülür. Kategori listesi; ‘Trafik Kazası’, ‘Yangın’, ‘Elektrik Kesintisi’, ‘Hırsızlık’, ‘Kültürel Etkinlikler’ ve ‘Diğer’ sınıflarından oluşmaktadır.

Kategoriler PRIORITY sırasıyla değerlendirilir: Trafik Kazası, Yangın, Elektrik Kesintisi, Hırsızlık, Kültürel Etkinlikler. En yüksek matchScore’a sahip kategori selectedCategory olarak döner; hiçbir kategori eşik değerini geçmezse (başlangıç ve eşik 20) sonuç Diğer kalır. Su kesintisi bağlamında (isSuKesintiContext) Elektrik Kesintisi puanı

kasıtlı olarak çok düşük atanır ve en iyi kategori yeniden seçilir; böylece yalnızca “kesinti” ile su haberlerinin elektrik sınıfına yanlış düşmesi azaltılır.

D. Kullanılan anahtar kelimeler

Anahtar kelimeler

Trafik Kazası (pozitif):

trafik kazası, trafik kazası, birbirine gir, çarpı, çarpma, çarpışma, çarpışmış, çarparak, zincirleme, direksiyon hakimiyeti, kaza, kazada, kazası, yaralan, yaralı, can kaybı, hayatını kaybetti.

Yangın (pozitif):

yangın, yangını, yangında, alev, itfaiye, duman, mahsur kal.

Elektrik Kesintisi (pozitif):

elektrik kesinti, kesinti, arıza, bakım çalışması, onarım çalışması, dağıtım şirketi.

Hırsızlık (pozitif):

hırsız, hırsızlık, kundakla, soygun, çaldı, çalmaya çalıştı, operasyon, gözaltı, yakalandı, şüpheli, polis, kamera kayıtları.

Kültürel Etkinlikler (pozitif):

konser, sergi, festival, etkinlik, tiyatro, gösteri, sahne al, kutlama, söyleşi, konferans, gala, şenlik, turnuva, yarışma, millet bahçesi, belediye etkinliği.

Olumsuz anahtar kelimeler

Trafik Kazası:

kazandı, kazanarak, kazanan, kazanıyor, galibiyet, maç, lig, skor, davası, mahkeme, çarpıcı, fiyatların çarpımı.

Yangın:

davası, dava, sanık, mahkeme, savcı, tutuklama, yargılan.

Elektrik Kesintisi:

su kesintisi, su kesintileri, su kesintisine, su kesintisinde, su kesintilerinde, içme suyu kesintisi, içme suyu kesintileri, su şebekesi kesintisi, su hattı kesintisi, su verilemeyecek, musluk suyu kesintisi.

Hırsızlık: tanımlı olumsuz terim yoktur.

Kültürel Etkinlikler: tanımlı olumsuz terim yoktur.

E. Konum Çıkarımı (İlçe - Mahalle - Cadde/Sokak)


Konum çıkarımı işlemi, haber başlığı ve içerik metnlerinin birleşik hali üzerinden regex tabanlı örüntüler ile yapılmaktadır. Sistem öncelikle mahalle veya cadde/sokak ifadelerini yakalamaya çalışır; ardından hal ekleriyle birlikte ilçe adlarını arar. İlçe listesi önceden tanımlı olarak Kocaeli'nin ilçe adlarından oluşur.

Çıkarım önceliği şu şekildedir:

- mahalle/sokak (örn. ‘... Mahallesi’, ‘... Sokağı’, ‘... Sok.’),
- ilçe (örn. hal ekleriyle ‘... da/de/ta/te/nda/nde ...’),
- ilçe (hal eki olmadan fallback).

Sonuç olarak, konum metni “adres, ilçe, Kocaeli, Türkiye” formatında veya eksik bileşenlere göre kısaltılmış biçimde

üretilmektedir. Konum metni bulunamazsa ilgili haber harita üzerinde gösterim için atlanmaktadır.



Şekil 3: Haberleri Haritada Gösterme

F. Koordinat Dönüştürme (Google Geocoding + Cache)

Konum metinleri, Google Geocoding API kullanılarak enlem (‘lat’) ve boylam (‘lon’) değerlerine dönüştürülmektedir. ‘geocodeLocation’ fonksiyonunda:

- API anahtarı ‘GOOGLE_GEOCODING_API_KEY’ ortam değişkeninden alınır,
- isteklerde ‘timeout= 8000 ms’ uygulanır,
- aynı konum metni için tekrar eden çağrılar azaltmak amacıyla in-memory cache tutulur,
- sonuçlar arasında ‘Kocaeli’ bileşeni bulunmuyorsa geocoding çıktısı reddedilir.

Böylece yalnızca Kocaeli sınırları ile uyumlu koordinatlar harita görselleştirmeye dahil edilmektedir.

G. Benzerlik Analizi ve Tekilleştirme

Farklı kaynaklarda aynı olaya ait benzer haberlerin tespiti için embedding tabanlı benzerlik analizi yapılmaktadır. ‘similarity.js’ içinde:


- Haber dokümanları başlık + içerik olarak birleştirilir,
- embedding modeli olarak ‘Xenova/paraphrase-multilingual-MiniLM-L12-v2’ kullanılır,
- embedding vektörleri arasında ‘cosineSimilarity’ hesaplanır,
- eşik değeri ‘threshold= 0.90’ alınarak benzer çiftler tekilleştirilir,
- farklı kaynaklar arasında birleştirme yapılır (aynı kaynak-taki farklı URL’ler otomatik birleştirilmez).

Embedding hesaplama aşamasında bir hata oluşursa ‘TF-IDF’ tabanlı vektörleme ile ‘cosineSimilaritySparse’ üzerinden yedek yaklaşım devreye alınmaktadır. Gruplama işlemi ‘Union-Find’ veri yapısı ile gerçekleştirilerek ilişkili benzer kayıtlar aynı grupta toplanır.

Benzerlik grupları birleştirildiğinde, birincil haber kaydı baz alınır ve o olayın farklı kaynakları ‘sources’ alanında bir araya getirilir.

H. Veritabanı Yönetimi ve API Katmanı

Veri saklama katmanında MongoDB veritabanı ve Mongoose nesne modelleme aracı kullanılmıştır. Haber verileri, News şeması içerisinde haber_id, type, title, content, locationText, coordinates, date, source, sources, classification ve link alanları ile tutulmaktadır.



Şekil 4: DB Kayıt Örneği

Sistem, Express tabanlı bir API mimarisi üzerinde çalışmaktadır. Uygulamada kullanılan temel endpoint'ler aşağıda verilmiştir:

- GET /api/news: type, startDate ve endDate filtrelerine göre güncel haberleri döndürür.
- GET /api/news/:haberId: ilgili haber kaydını haber_id bilgisine göre sorgular.
- GET /api/fetch-progress: scraping işlemi sırasında kullanıcı arayüzünde gösterilen ilerleme bilgisini iletir.
- POST /fetch-news: belirlenen gün sayısına göre veri güncelleme sürecini başlatır.

Uygulama ayrıca 'GET /' ile arayüz sayfasını servis eder ve 'public/' klasörü statik içerikleri sunar.

I. Harita Tabanlı Görselleştirme

Ön yüz 'Google Maps JavaScript API' ile yüklenir. Harita üzerinde her haber, olay türüne göre farklı renk ve ikonlarla temsil edilen marker olarak gösterilir. Yoğun bölgelerde aynı koordinatın üst üste binmesini azaltmak için:

- benzer koordinatlar 'toFixed(4)' ile gruplanır,
- aynı noktaya düşen marker'lar küçük bir yayılım ('SP-READ_DEG= 0.00014') ile dağıtılır,
- 'markerclusterer' kullanılarak küme görünimleri oluşturulur.

Marker tıklandığında seçili haber(ler) için özelleştirilmiş bir 'InfoWindow' içeriği açılır. Bu pencerede haber başlığı, tarih ve kaynak bilgileri gösterilir. UI tarafında ayrıca tarih aralığı ve ilçe filtreleme, sunucudan gelen veriler üzerinde yerel olarak da desteklenmektedir.

III. AKIŞ DIYAGRAMI VE YALANCI KODLAR

Bu bölümde sistemin ana kontrol akışı ve harita görselleştirme süreci yalancı kod biçiminde verilmektedir.

A. Haber İçerik Aktarma ve Tekilleştirme Akışı

Yalancı Kod:

```
BAŞLA
days değerini al
Veritabanındaki tüm haber kayıtlarını sil
haber_id sayacını sıfırla
snapshot durumlarını sıfırla
allScrapedItems ← boş liste
mergedItems ← boş liste
FOR EACH kaynak IN kaynakListesi DO
  items ← kaynaktan cutoffDate'e uygun
  haberleri çek
  allScrapedItems ← allScrapedItems U
  items
END FOR
groups ←
BenzerHaberGruplarınıBul(allScrapedItems)
FOR EACH grup IN groups DO
  primary ← grubun ilk elemanı
  primary.sources ← gruptaki farklı
  kaynak bilgileri
  mergedItems ← mergedItems U {primary}
END FOR
FOR EACH haber IN mergedItems DO
  temizBaslik ←
  MetniTemizle(haber.title)
  temizIcerik ←
  MetniTemizle(haber.content)
  kategori ←
  HaberiSiniflandir(temizBaslik,
  temizIcerik)
  konum ← KonumCikar(temizBaslik,
  temizIcerik)
  IF konum = bos ISE
    DEVAM ET
  END IF
  koordinat ← GeocodeEt(konum)
  IF koordinat = gecersiz ISE
    DEVAM ET
  END IF
  MongoDB'yeKaydet(haber, kategori,
  konum, koordinat)
END FOR
BİTİR
```

B. Harita Görselleştirme Akışı

Yalancı Kod:

```
BAŞLA
news ← filtrelenmiş haber listesi
IF öncekiMarkerlarVar ISE
  MarkerlariTemizle()
END IF
groupsByCoord ←
KoordinataGoreGrupla(news)
FOR EACH grup IN groupsByCoord DO
  itemsAtPoint ← gruptaki haberler
  n ← grup eleman sayısı
  FOR EACH haber IN itemsAtPoint DO
    yayilmisKonum ←
YayilimliKonumHesapla(haber, n)
    ikon ← IkonSec(haber.type)
    marker ←
MarkerOlustur(yayilmisKonum, ikon)
    BilgiPenceresiBagla(marker, haber)
  END FOR
END FOR
ClusterYapisinaEkle()
HaritadaGoster()
BİTİR
```

IV. DENEYSEL SONUÇLAR

Sistem; geliştirme ortamında uçtan uca çalıştırılarak çekim, işleme ve görselleştirme aşamalarının doğru şekilde tetiklendiği doğrulanmıştır. Aşağıda test edilen başlıca senaryolar yer almaktadır.

A. Kaynaklardan Çekim ve Tarih Doğrulama

Cloudflare korumasına sahip kaynaklarda tarayıcı tabanlı oturum açma süreci çalıştırılmış; challenge başlıkları tespit edilerek sayfanın içerik üretmesi beklenmiştir. Diğer kaynaklarda 'axios + cheerio' ile HTML içeriklerinden haber bağlantıları ve detay sayfaları okunmuştur. İstenilen gün aralığı sınırı için yayın tarihi doğrulanarak cutoff tarihinden önceki haberler atlanmıştır.

B. Sınıflandırma Performansı

Anahtar kelime tabanlı sınıflandırma yaklaşımında; başlık ve içerik birlikte kullanılarak olay türü seçimi yapılmıştır. Negatif anahtar kelimeler ile yanlış pozitif durumlar azaltılacak şekilde ceza mekanizması uygulanmıştır. Böylece trafik, yangın, elektrik kesintisi, hırsızlık ve kültürel etkinlik kategorileri için tutarlı bir etiketleme sağlanmıştır.

C. Konum Çıkarma ve Geocoding Doğruluğu

Konum çıkarma aşamasında mahalle/sokak ifadeleri önce, ilçe ifadeleri ise öncelik sırasına göre aranmıştır. Geocoding adımı ise:

- aynı konum metni için cache kullanılarak tekrar istekler azaltılmış,

- sonuç 'Kocaeli' ile ilişkilendirilemiyorsa kayıt atlanmıştır,
- koordinat üretilmeyen haberler MongoDB'ye kaydedilmemiştir.

D. Benzerlik Analizi ve Kaynak Birleştirme

Benzerlik gruplama aşamasında embedding tabanlı cosine similarity kullanılmış; eşik değeri 0.90 olarak uygulanmıştır. Embedding hesaplamasında bir hata oluşması durumunda TF-IDF fallback devreye alınarak analiz sürekliliği sağlanmıştır. Ayrıca sadece farklı kaynaklar arasında birleştirme yapılması hedeflenmiş; böylece aynı kaynaktaki farklı URL'lerin yanlış birleştirilmesi engellenmiştir.

E. Harita Üzerinde Görselleştirme ve Filtreleme

UI tarafında Google Maps yüklendikten sonra marker'lar oluşturulmuştur. Aynı koordinat üzerinde birden fazla haber bulunması durumunda marker çakışması azaltmak için yayılım uygulanmıştır. Ayrıca markerclusterer ile yoğun noktalar kümelenecek performans ve okunabilirlik artırılmıştır. Kullanıcı tarafından seçilen olay türü ve tarih aralığı filtreleri ile veri seti güncellenmiş; markerların ve listelenen haber kartlarının senkron şekilde değiştiği gözlemlenmiştir.

V. SONUÇ

Bu çalışmada, Kocaeli iline ait yerel haber kaynaklarından otomatik veri toplayan, metinleri ön işleyip anahtar kelime tabanlı yöntemle sınıflandıran, metinden konum ifadelerini çıkararak Google Geocoding API ile koordinatlara dönüştüren ve embedding tabanlı benzerlik analiziyle tekrar/benzer haberleri tekilleştiren bir kentsel haber izleme sistemi geliştirilmiştir. Express ve MongoDB ile arka uçta veri yönetimi sağlanmış; Google Maps tabanlı arayüz ile kullanıcıların olayları konum üzerinde etkileşimli şekilde takip edebilmesi mümkün kılınmıştır.

Elde edilen sonuçlar, farklı kaynaklarda dağınık halde bulunan şehir içi olay bilgilerinin tek bir platformda bütünleştirilmesine olanak tanımaktadır. Benzerlik analizi ve kaynak birleştirme mekanizmaları veri bütünlüğünü güçlendirirken; konum çıkarımı ve geocoding adımları harita tabanlı görselleştirmeyi işlevsel hale getirmiştir.

Gelecekte, kategori sayısının artırılması, konum çıkarımında daha gelişmiş adlandırılmış varlık tanıma (NER) yöntemlerinin kullanılması, geocoding cache'inin kalıcı hale getirilmesi ve kullanıcı geri bildirimleri ile sınıflandırma skorlarının iyileştirilmesi gibi çalışmalar yapılabilir. Ayrıca sistemin daha geniş veri kaynaklarına ölçeklenmesi ve daha sık güncelleme senaryolarında performans optimizasyonu hedeflenebilir.

VI. YAZAR KATKILARI

Saffet Hakan Koak ve Yusuf Blbl, projenin tm aamalarını ortaklaa yrtmtr. Veri toplama (scraping), veri temizleme, haber sınıflandırma, konum ıkarımı, koordinat dntrme, benzerlik analizi/tekkilletirme, veritabanı ve API katmanı gelitirme ile arayz entegrasyonu gibi i paketleri her iki yazar tarafından eit sorumluluk ve i birliėi ile gerekletirilmitir. Raporun hazırlanması ve nihai dzenlemeler de yazarlar arasında tam bir uyum ve koordinasyon iinde tamamlanmıtır.

KAYNAKLAR

- [1] Puppeteer, *Puppeteer Documentation*, [evrimii]. Eriim: <https://pptr.dev/>
- [2] Cheerio, *Cheerio Documentation*, [evrimii]. Eriim: <https://cheerio.js.org/>
- [3] Express.js, *Express Documentation*, [evrimii]. Eriim: <https://expressjs.com/>
- [4] MongoDB, *MongoDB Documentation*, [evrimii]. Eriim: <https://www.mongodb.com/docs/>
- [5] Google Maps Platform, *Geocoding API*, [evrimii]. Eriim: <https://developers.google.com/maps/documentation/geocoding/overview>
- [6] D. Jurafsky and J. H. Martin, *Speech and Language Processing*. Draft, 2nd ed., 2024.
- [7] R. A. Fisher, “Statistical methods for research workers,” Cosine similarity ilikili rneklem alımaları, 1958.
- [8] Hugging Face, *Transformers: Xenova Models / Feature Extraction*, [evrimii]. Eriim: <https://huggingface.co/docs/transformers/>